

INF672 / Unidad 2 / GL03

GUÍA DE LABORATORIO

Álgebra lineal para Machine Learning, escrita en NumPy

La matemática del ML escrita en código: vectores, producto punto, norma y similitud, sobre el dataset iris.

Tema 2.1.1 · Vectores, matrices y producto punto

Machine Learning · 6º semestre · Gestión 2026-02

Duración: 3 h de laboratorio · Dataset: iris

UATF · Ing. Informática · Docente: M.Sc. Huáscar Fedor Gonzales Guzmán

NOTA Convenciones de esta guía

In [] / Out[] = celdas de Jupyter con su código y su resultado. Las **bandas centradas** son fórmulas. Reproduce cada celda en tu cuaderno.

01 Competencia y objetivos

Competencia de la práctica

Representa datos como vectores y matrices en NumPy y calcula, a mano y con la librería, las operaciones fundamentales del álgebra lineal —producto punto, norma, distancia y similitud coseno— interpretándolas como medidas de parecido y cercanía entre muestras, que son la base geométrica de los algoritmos de Machine Learning.

Objetivos específicos

Al finalizar la sesión, el o la estudiante será capaz de:

- Representar un conjunto de datos como una matriz y cada muestra como un vector en NumPy.
- Ejecutar operaciones vectoriales y matriciales básicas (acceso por filas y columnas, transpuesta, suma y escalado).
- Calcular el producto punto a mano y con NumPy, e interpretarlo como una medida de similitud entre muestras.
- Calcular la norma de un vector y la distancia euclidiana entre dos muestras.
- Medir la similitud coseno entre muestras y comparar el resultado entre flores de la misma y de distinta especie.

02 Requisitos previos

Esta práctica se apoya en las dos guías anteriores de la unidad:

- Entorno inf672 activo con Jupyter, tal como se instaló en la GL01.
- Manejo básico de NumPy (arreglos, indexado y slicing) visto en la GL02.
- El dataset iris disponible a través de sklearn.datasets.

03 Marco conceptual

Este laboratorio no es un repaso de matemáticas de pizarra: es la matemática del Machine Learning escrita en código. Cada concepto vector, matriz, producto punto, norma se calcula a mano en NumPy y se conecta con algo que ya sabes hacer con datos: representar muestras y medir en qué se parecen y cuán lejos están unas de otras.

DEFINICIÓN Vector y matriz

Un vector es una lista ordenada de números; en ML representa una muestra (una fila de datos). Una matriz es una tabla de números; representa el conjunto de datos completo, con una fila por muestra y una columna por característica.

Un dataset con n muestras y d características es una matriz X de tamaño $n \times d$. Cada muestra es un vector con d componentes.

DEFINICIÓN Producto punto

El producto punto (o producto escalar) de dos vectores multiplica sus componentes una a una y suma los resultados, dando un solo número.

$$a \cdot b = a_1b_1 + a_2b_2 + \dots + a_db_d$$

DEFINICIÓN Norma, distancia y coseno

La norma $\|a\|$ mide la longitud de un vector. La distancia euclidiana entre dos muestras es la norma de su diferencia. La similitud coseno mide el ángulo entre dos vectores: vale 1 cuando apuntan igual y baja a medida que se separan.

$$\|a\| = \sqrt{a \cdot a}$$

$$d(a, b) = \|a - b\|$$

$$\cos(\theta) = (a \cdot b) / (\|a\| \cdot \|b\|)$$

04 Los datos como vectores y matrices

Cargamos iris y observamos su forma. La estructura que NumPy nos entrega ya es una matriz.

In [1]:

```
from sklearn.datasets import load_iris
import numpy as np
```

```
iris = load_iris()
X = iris.data      # matriz de características
y = iris.target    # etiquetas: 0, 1, 2
print(X.shape)
print(iris.feature_names)
```

Out[1]:

```
(150, 4)
['sepal length (cm)', 'sepal width (cm)',
 'petal length (cm)', 'petal width (cm)']
```

X tiene 150 filas y 4 columnas: 150 muestras, cada una con 4 medidas. Es una matriz de 150×4 , y cada fila es un vector de 4 componentes.

In [2]:

```
x0 = X[0]          # primera muestra: un vector
print(x0)
print(x0.shape)
```

Out[2]:

```
[5.1 3.5 1.4 0.2]
(4,)
```

Una muestra (una flor) es un vector de 4 componentes: largo y ancho de sépalo, largo y ancho de pétalo.

In [3]:

```
# fila = muestra ; columna = característica
col_2 = X[:, 2]    # 3ª característica de TODAS las muestras
print(col_2[:5])
print(col_2.shape)
```

Out[3]:

```
[1.4 1.4 1.3 1.5 1.4]
(150,)
```

In [4]:

```
print(X.shape)      # (150, 4)
print(X.T.shape)    # transpuesta: (4, 150)
```

Out[4]:

```
(150, 4)
(4, 150)
```

La transpuesta intercambia filas por columnas. Es una operación de reorganización que aparece con frecuencia al operar con matrices.

In [5]:

```
a = X[0]            # una flor setosa
b = X[50]           # una flor versicolor
print('a + b =', a + b)
print('2 * a =', 2 * a)
```

Out[5]:

```
a + b = [12.1 6.7 6.1 1.6]
2 * a = [10.2 7.  2.8 0.4]
```

Sumar dos vectores y multiplicar por un escalar operan componente a componente. Son las operaciones básicas del espacio vectorial en el que viven los datos.

05 Producto punto y similitud

El producto punto condensa dos vectores en un solo número. Lo calculamos a mano y lo comparamos con NumPy.

In [6]:

```
manual = sum(ai * bi for ai, bi in zip(a, b))
print('a mano :', round>manual, 2))
print('np.dot :', round(np.dot(a, b), 2))
print('con @ :', round(a @ b, 2))
```

Out[6]:

```
a mano : 53.76
np.dot : 53.76
con @ : 53.76
```

Los tres caminos dan el mismo resultado. En NumPy usarás `np.dot(a, b)` o el operador `a @ b`.

ADVERTENCIA Producto punto ≠ producto elemento a elemento

En NumPy, `a * b` NO es el producto punto: multiplica componente a componente y devuelve un vector, no un número.

In [.]:

```
a * b          # multiplicación elemento a elemento
```

Out[.]:

```
array([35.7 , 11.2 ,  6.58,  0.28]) # ¡es un vector!
```

El producto punto sirve para medir similitud. La forma más usada es la similitud coseno, que se fija en la dirección de los vectores e ignora su tamaño.

$$\cos(\theta) = (a \cdot b) / (||a|| \cdot ||b||)$$

In [7]:

```
def coseno(u, v):
    return np.dot(u, v) / (np.linalg.norm(u) * np.linalg.norm(v))

print('cos(a, b) =', round(coseno(a, b), 4))
```

Out[7]:

```
cos(a, b) = 0.9283
```

Ahora comparamos dos flores de la misma especie contra dos de especies distintas. Esperamos que las de la misma especie se parezcan más.

In [8]:

```
setosa1 = X[0]
setosa2 = X[1]
versicolor = X[50]
print('cos(setosa1, setosa2) =', round(coseno(setosa1, setosa2), 4))
print('cos(setosa1, versicolor) =', round(coseno(setosa1, versicolor), 4))
```

Out[8]:

```
cos(setosa1, setosa2) = 0.9984
cos(setosa1, versicolor) = 0.9283
```

EJEMPLO Lectura del resultado

Las dos setosas tienen un coseno más cercano a 1 (0.9984) que el par setosa–versicolor (0.9283). La similitud coseno confirma, con un número, algo que ya intuías: las flores de la misma especie se parecen más entre sí.

06 Norma y distancia

La norma mide la longitud de un vector; la distancia euclidiana entre dos muestras es la norma de su diferencia.

$$d(a, b) = \|a - b\| = \sqrt{(\sum (a_i - b_i)^2)}$$

In [9]:

```
def distancia(u, v):
    return np.linalg.norm(u - v)

print('d(setosa1, setosa2) =', round(distancia(setosa1, setosa2), 4))
print('d(setosa1, versicolor) =', round(distancia(setosa1, versicolor), 4))
```

Out[9]:

```
d(setosa1, setosa2) = 0.5385
d(setosa1, versicolor) = 4.0037
```

Las dos setosas están mucho más cerca (0.54) que la setosa de la versicolor (4.00). Distancia pequeña y coseno cercano a 1 cuentan la misma historia desde ángulos distintos.

NOTA Norma y producto punto son la misma familia

La norma no es independiente del producto punto: $\|x\|^2$ es exactamente $x \cdot x$. Comprobémoslo.

$$\|x\|^2 = x \cdot x$$

In [10]:

```
x = X[0]
```

```
print('x · x      =', round(np.dot(x, x), 4))
print('||x|| ** 2 =', round(np.linalg.norm(x) ** 2, 4))
```

Out[10]:

```
x · x      = 40.26
||x|| ** 2 = 40.26
```

07 Entregable evaluable

Elabora un notebook que resuelva, con NumPy, la siguiente consigna. Todo se calcula con `np.dot` y `np.linalg.norm`; no se permiten funciones de distancia, similitud ni predicción de scikit-learn.

EJEMPLO Qué entregar

Archivo: GL03_Apellido_Nombre.ipynb

1. Carga iris y selecciona 3 muestras: dos de una misma especie y una de otra. Documenta con un comentario los índices elegidos.
2. Construye la matriz 3×3 de distancias euclidianas entre las tres muestras.
3. Construye la matriz 3×3 de similitud coseno entre las tres muestras.
4. Verifica, para una de las muestras, que $\|x\|^2 = x \cdot x$.
5. En una celda Markdown, responde en 3–4 líneas: ¿qué par es más parecido según el coseno? ¿coincide con el par más cercano según la distancia? ¿por qué?

NOTA Entrega

Sube el archivo .ipynb ejecutado (con las salidas visibles) al aula virtual antes del inicio del siguiente laboratorio.

08 Rúbrica de evaluación

Criterio	Descripción	Pts.
Representación de datos	Carga de iris y representación correcta como matriz y vectores.	20
Producto punto	Implementado y verificado (a mano vs. NumPy).	20
Norma y distancia	Correctas; matriz 3×3 de distancias euclidianas.	20
Similitud coseno	Correcta; matriz 3×3 de similitud coseno.	20
Interpretación	Lectura escrita coherente y bien argumentada.	10
Código	Orden, comentarios y buenas prácticas.	10

Total: 100 puntos

09 Referencias

- Raschka, S. & Mirjalili, V. — Python Machine Learning (bibliografía oficial de la asignatura).
- Deisenroth, Faisal & Ong — Mathematics for Machine Learning (disponible en <https://mml-book.github.io>).
- Álgebra lineal en NumPy: <https://numpy.org/doc/stable/reference/routines.linalg.html>
- Dataset iris en scikit-learn: https://scikit-learn.org/stable/datasets/toy_dataset.html