

INF672 / Unidad 2 / 2.1.3

REPASO MATEMÁTICO ORIENTADO AL MACHINE LEARNING

GL5 · Estadística descriptiva

*Describir los datos antes de modelarlos — con NumPy y Pandas sobre el dataset iris***MATERIA** Machine Learning · Ing. Informática · UATF **DOCENTE** M. Sc. Huáscar F. Gonzales G. **GESTIÓN** 2026-02

Esta guía de laboratorio acompaña al documento teórico del tema **2.1.3**. Es un **repaso**: la teoría completa la cursas en Probabilidad y Estadística. Aquí reactivamos solo lo que el Machine Learning usa a diario — resumir y describir los datos— calculándolo con **NumPy** y **Pandas** sobre el dataset **iris**. Ejecuta las celdas en orden con **Shift + Enter**.

01 Objetivos de aprendizaje

Al finalizar el laboratorio, cada estudiante será capaz de:

- Calcular **medidas de tendencia central y de dispersión** con NumPy/Pandas sobre un dataset real.
- Explicar por qué la **mediana es robusta** frente a outliers y decidir cuándo preferirla a la media.
- Interpretar la **forma de una distribución** a partir de su histograma: centro, dispersión, sesgo y número de modas.
- Calcular e interpretar la **matriz de correlación de Pearson** y relacionarla con la similitud coseno del álgebra lineal.
- Conectar cada medida descriptiva con una **decisión concreta del flujo de ML** (imputación, escalado, selección de características).

02 Requisitos previos y entorno

- Python 3 con **numpy**, **pandas**, **matplotlib** y **scikit-learn** instalados.
- Entorno de notebooks: Jupyter Lab / Notebook, VS Code o Google Colab.
- Nociones previas de arreglos NumPy y DataFrames de Pandas (GL anteriores).

NOTA

Si te falta alguna librería, instálala con `pip install numpy pandas matplotlib scikit-learn`. El dataset **iris** viene incluido en **scikit-learn**: no necesitas descargar nada.

03 Marco teórico breve

Cuatro ideas sostienen todo el laboratorio. Recuérdalas antes de programar.

DEFINICIÓN

Tendencia central. dónde está el centro de los datos. La **media** es el promedio aritmético, la **mediana** el valor central al ordenar, y la **moda** el valor más frecuente.

$$\bar{x} = (1/n) \cdot \sum x_i$$

◆ DEFINICIÓN

Dispersión. cuánto se alejan los datos del centro. La **varianza** promedia las distancias al cuadrado a la media; la **desviación estándar** (σ) es su raíz y vuelve a las unidades originales.

$$\sigma^2 = (1/n) \cdot \sum (x_i - \bar{x})^2 \quad \sigma = \sqrt{\sigma^2}$$

◆ DEFINICIÓN

Correlación de Pearson. mide la relación lineal entre dos variables, normalizada al rango $[-1, +1]$: +1 relación positiva perfecta, 0 sin relación lineal, -1 negativa perfecta.

$$\text{corr}(x, y) = \cos(x - \bar{x}, y - \bar{y}) = (x - \bar{x}) \cdot (y - \bar{y}) / (\|x - \bar{x}\| \cdot \|y - \bar{y}\|)$$

04 Desarrollo — actividades guiadas

Reproduce cada celda y compara tu salida con la esperada. Los recuadros **In []** son código que escribes; los **Out[]** son la salida que debes obtener.

4.0 Preparación del entorno

Importamos las librerías, fijamos la paleta de la materia para que los gráficos combinen con el documento y cargamos el dataset en un DataFrame.

```
In [1]:
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import load_iris

# --- paleta INF672 (para que los gráficos combinen con el documento) ---
INDIGO, PURPLE, CORAL, INK, GREY = "#4F46E5", "#7E22CE", "#F43F5E", "#111827", "#6B7280"
plt.rcParams.update({
    "axes.edgecolor": "#D1D5DB", "axes.titleweight": "bold", "axes.titlecolor": INK,
    "axes.labelcolor": INK, "text.color": INK, "xtick.color": INK, "ytick.color": INK,
    "axes.grid": True, "grid.color": "#E5E7EB", "grid.linewidth": 0.7, "axes.axisbelow":
    True,
    "figure.dpi": 110,
})

iris = load_iris()
df = pd.DataFrame(iris.data, columns=["sep_largo", "sep_ancho", "pet_largo", "pet_ancho"])
print("Forma del dataset:", df.shape)
df.head()
```

```
Out[1]:
Forma del dataset: (150, 4)
```

	sep_largo	sep_ancho	pet_largo	pet_ancho
0	5.1	3.5	1.4	0.2
1	4.9	3.0	1.4	0.2
2	4.7	3.2	1.3	0.2
3	4.6	3.1	1.5	0.2
4	5.0	3.6	1.4	0.2

4.1 Tendencia central: media, mediana y moda

```
In [2]:
col = df["pet_largo"]
print("media :", round(col.mean(), 3))
print("mediana :", round(col.median(), 3))
print("moda :", col.mode().tolist()) # la moda es más útil en variables
discretas/categóricas
```

Out[2]:

```
media    : 3.758
mediana  : 4.35
moda     : [1.4, 1.5]
```

La media (3.76) y la mediana (4.35) **no coinciden**: los datos no son simétricos. Hay un grupo de flores muy pequeñas —la especie *setosa*— que jala la media hacia abajo.


La idea que importa: la mediana es robusta

Inyectamos un valor absurdo en el ancho del sépalos y observamos qué le pasa a cada medida.

In [3]:

```
base = df["sep_ancho"].values
conout = np.append(base, 12.0)      # un ancho de sépalos imposible

fig, axes = plt.subplots(1, 2, figsize=(9, 3.2))
for ax, data, titulo in [(axes[0], base, "Sin outlier"),
                          (axes[1], conout, "Con un outlier (12.0)"]):
    ax.hist(data, bins=18, color=INDIGO, alpha=0.7, edgecolor="white", linewidth=0.5)
    ax.axvline(data.mean(), color=CORAL, lw=2.2, label=f"media={data.mean():.2f}")
    ax.axvline(np.median(data), color=PURPLE, lw=2.2, ls="--",
    label=f"mediana={np.median(data):.2f}")
    ax.set_title(titulo); ax.set_xlabel("Ancho del sépalos (cm)"); ax.legend(fontsize=9)
axes[0].set_ylabel("Frecuencia")
fig.suptitle("Un solo outlier arrastra la media, no la mediana", fontweight="bold")
plt.tight_layout(); plt.show()
```

Out[3]:

Un único valor extremo desplaza la **media** pero deja casi intacta la **mediana**. Esa insensibilidad a los outliers es lo que llamamos robustez.

● CONEXIÓN ML

Cuando en el preprocesamiento rellenes valores faltantes (tema 2.3.1), elegirás media o mediana según haya outliers: la **mediana es la opción segura**. La misma robustez es la base de varias técnicas de detección de anomalías.

4.2 Dispersión: varianza y desviación estándar

La desviación estándar σ es la que se interpreta, porque vuelve a las unidades originales (cm). Calculamos también un resumen de las cuatro características a la vez.

```
In [4]:
print("varianza :", round(col.var(ddof=0), 3))
print("desv.  $\sigma$  :", round(col.std(ddof=0), 3))

# Resumen de las cuatro características a la vez:
resumen = pd.DataFrame({
    "media": df.mean().round(2),
    "mediana": df.median().round(2),
    "desv_σ": df.std(ddof=0).round(2),
    "min": df.min().round(2),
    "max": df.max().round(2),
})
resumen
```

```
Out[4]:
varianza : 3.096
desv.  $\sigma$  : 1.759
```

	media	mediana	desv_σ	min	max
sep_largo	5.84	5.80	0.83	4.3	7.9
sep_ancho	3.06	3.00	0.43	2.0	4.4
pet_largo	3.76	4.35	1.76	1.0	6.9
pet_ancho	1.20	1.30	0.76	0.1	2.5

NOTA

el **ddof**. `np.var / np.std` dividen entre n (varianza poblacional). Pandas divide entre $n-1$ (`ddof=1`, varianza muestral). Con 150 datos la diferencia es mínima; solo conviene saber que existe.

El `pet_largo` se esparce mucho más ($\sigma \approx 1.76$) que el `sep_ancho` ($\sigma \approx 0.43$).

CONEXIÓN ML

Cuando las características viven en escalas muy distintas, los modelos basados en distancia (KNN, K-means) y en gradiente se dejan dominar por la de mayor dispersión. Medir la dispersión es el primer paso hacia el **escalado de características** (tema 2.3.3).


4.3 La forma de la distribución: leer un histograma

Media y desviación resumen los datos en dos números, pero **pierden la forma**. El histograma la recupera: revela el centro, la dispersión, el sesgo y cuántos picos (modas) hay.

In [5]:

```
p1 = df["pet_largo"].values
plt.figure(figsize=(6.4, 3.4))
plt.hist(p1, bins=20, color=INDIGO, alpha=0.75, edgecolor="white", linewidth=0.6)
plt.axvline(p1.mean(), color=CORAL, lw=2.2, label=f"media = {p1.mean():.2f}")
plt.axvline(np.median(p1), color=PURPLE, lw=2.2, ls="--", label=f"mediana = {np.median(p1):.2f}")
plt.xlabel("Largo del pétalo (cm)"); plt.ylabel("Frecuencia")
plt.title("Distribución del largo del pétalo (iris)"); plt.legend()
plt.tight_layout(); plt.show()
```

Out[5]:



Este histograma es **bimodal**: el grupo de la izquierda son las flores *setosa*, separadas del resto. Ese hueco explica por qué la media caía donde casi no hay datos: cuando la distribución no es unimodal ni simétrica, la media sola engaña.

● CONEXIÓN ML

Una característica bimodal probablemente **separa bien las clases**; un sesgo fuerte sugiere transformar la variable; una cola larga delata outliers. Es la puerta de entrada a la distribución Normal.

4.4 Relación entre dos variables: correlación

La correlación de Pearson normaliza la covarianza al rango $[-1, +1]$. Con una sola llamada obtenemos la matriz de todas las parejas.

In [6]:

```
df.corr().round(2)
```


	sep_largo	sep_ancho	pet_largo	pet_ancho
sep_largo	1.00	-0.12	0.87	0.82
sep_ancho	-0.12	1.00	-0.43	-0.37
pet_largo	0.87	-0.43	1.00	0.96
pet_ancho	0.82	-0.37	0.96	1.00

El mismo dato se lee mejor como mapa de calor:

In [7]:

```
C = df.corr().values
labels = ["sépalolargo", "sépalon ancho", "pétalolargo", "pétalon ancho"]
fig, ax = plt.subplots(figsize=(5, 4.2))
im = ax.imshow(C, cmap="PuOr", vmin=-1, vmax=1)
ax.set_xticks(range(4), labels, fontsize=9); ax.set_yticks(range(4), labels, fontsize=9)
for i in range(4):
    for j in range(4):
        ax.text(j, i, f"{C[i,j]:.2f}", ha="center", va="center",
                color="white" if abs(C[i,j]) > 0.55 else "black", fontweight="bold")
ax.set_title("Matriz de correlación (iris)"); ax.grid(False)
fig.colorbar(im, fraction=0.046, pad=0.04); plt.tight_layout(); plt.show()
```

Out[7]:




El par más correlacionado es largo vs. ancho del pétalo. Lo vemos en un diagrama de dispersión con su recta de ajuste:

In [8]:

```
x, y = df["pet_largo"].values, df["pet_ancho"].values
r = np.corrcoef(x, y)[0, 1]
b1, b0 = np.polyfit(x, y, 1)
plt.figure(figsize=(6, 3.6))
plt.scatter(x, y, color="INDIGO", alpha=0.6, edgecolor="white", linewidth=0.4, s=38)
```

```
plt.plot([x.min(), x.max()], b0 + b1*np.array([x.min(), x.max()]), color=CORAL, lw=2)
plt.xlabel("Largo del pétalo (cm)"); plt.ylabel("Ancho del pétalo (cm)")
plt.title(f"Dos características muy correlacionadas (r = {r:.2f})")
plt.tight_layout(); plt.show()
```

Out[8]:



El puente con el álgebra lineal (tema 2.1.1)

La correlación de Pearson es **exactamente el coseno del ángulo entre los vectores centrados** (a cada variable se le resta su media). Es la misma similitud coseno del producto punto que viste en álgebra lineal. Compruébalo numéricamente:

In [9]:

```
xc, yc = x - x.mean(), y - y.mean()
cos = xc @ yc / (np.linalg.norm(xc) * np.linalg.norm(yc))
print("Pearson (np.corrcoef) :", round(np.corrcoef(x, y)[0, 1], 6))
print("coseno centrado      :", round(float(cos), 6))
print("¿idénticos? ->", np.isclose(np.corrcoef(x, y)[0, 1], cos))
```

Out[9]:

```
Pearson (np.corrcoef) : 0.962865
coseno centrado      : 0.962865
¿idénticos? -> True
```

● CONEXIÓN ML

Dos características muy correlacionadas (aquí 0.96) cargan casi la misma información: una es casi **redundante**. Detectarlo guía la **selección de características** (tema 2.4) y previene problemas en modelos lineales.

05 Entregable y criterios de evaluación

Entrega un único notebook `.ipynb` (o su exportación a PDF) con las actividades guiadas reproducidas y los seis ejercicios propuestos resueltos e interpretados. Nombra el archivo `GL05_ApellidoNombre.ipynb`.

Criterio	Descripción	Pts.
Reproducción guiada	Las celdas <code>In[1]</code> – <code>In[9]</code> corren sin error y coinciden con las salidas esperadas.	80
Claridad y estilo	Notebook ordenado, celdas Markdown de comentario, gráficos legibles.	20
TOTAL		100

06 Síntesis y fronteras

Concepto	En NumPy / Pandas	Para qué en ML
Media / mediana	<code>.mean()</code> / <code>.median()</code>	Imputar faltantes (2.3.1); mediana robusta
Varianza / desviación	<code>.var()</code> / <code>.std()</code>	Ver escalas → escalado (2.3.3)
Histograma	<code>plt.hist(...)</code>	Intuición de forma; separar clases
Correlación	<code>df.corr()</code>	Redundancia → selección (2.4); puente al coseno

Fin de la guía · INF672 / Unidad 2 / 2.1.3 – Estadística descriptiva