

INF672 · MACHINE LEARNING · UNIDAD 3

Práctica 2

Regresión lineal múltiple: predecir el costo anual de un seguro médico

En esta práctica vas a resolver un problema completo: entrenar un modelo de **regresión lineal múltiple** que prediga el costo anual del seguro médico de una persona a partir de sus características. A diferencia de la Práctica 1, los pasos no son ejercicios independientes: forman **un solo flujo de trabajo**, y cada paso usa lo que obtuviste en el anterior. Lee el **contexto** de cada paso, sigue las instrucciones en orden y responde las preguntas del bloque **Para entregar**.

Esta práctica es un **trabajo individual**. Las respuestas escritas deben apoyarse en los resultados que tú obtengas al ejecutar tu código: no basta con mostrar números, hay que interpretarlos en el contexto del problema.

Para entregar tu trabajo desarrolla un notebook de Jupyter que incluya tanto el código ejecutado como tus respuestas escritas en celdas de texto, organizado con un título por cada paso. Súbelo a tu repositorio de GitHub junto con el archivo de datos y envía el enlace a la plataforma virtual en el apartado de Práctica 2.

EL PROBLEMA

¿Cuánto costará asegurar a esta persona?

Una compañía de seguros de salud necesita estimar, antes de firmar un contrato, cuánto le costará en gastos médicos cada nuevo asegurado durante un año. Si subestima el costo, pierde dinero; si lo sobrestima, cobra primas demasiado altas y pierde clientes. La compañía dispone del historial de 1 338 asegurados y te pide un modelo que, con la información que se recoge en la solicitud del seguro, estime el costo médico anual.

Además de predecir bien, la compañía necesita **entender** el modelo: quiere saber qué características de una persona encarecen el seguro y en qué medida. Por eso se usará regresión lineal múltiple, un modelo cuyos coeficientes pueden interpretarse directamente en dólares.

EL DATASET

Archivo `insurance.csv`

El archivo `insurance.csv` contiene **1 338 filas** (una por asegurado) y **7 columnas**. Es el conjunto de datos público *Medical Cost Personal Dataset*, construido a partir de estadísticas demográficas de Estados Unidos. Seis columnas describen al asegurado y la séptima, `charges`, es la variable que el modelo debe predecir.

Variable	Tipo	Descripción
age	Numérica	Edad del titular del seguro, en años.
sex	Categórica	Sexo del titular: female o male .
bmi	Numérica	Índice de masa corporal: peso (kg) dividido entre la estatura al cuadrado (m ²). Valores de 18.5 a 24.9 se consideran peso normal y de 30 o más, obesidad.
children	Numérica discreta	Número de hijos o dependientes cubiertos por el seguro.
smoker	Categórica	Indica si la persona fuma: yes o no .
region	Categórica	Región de residencia en EE. UU.: northeast , northwest , southeast o southwest .
charges	Numérica (objetivo)	Costo médico anual facturado por el seguro, en dólares (USD). Es la variable a predecir.

Observa que tres de las variables de entrada contienen texto y no números, así que no pueden entrar al modelo tal como están. El procedimiento que sigue te guía por todas las etapas necesarias: preparar los datos, entrenar el modelo, evaluarlo, interpretarlo y usarlo para predecir.

PASO 01

Preparar el entorno de trabajo

Todo el trabajo se apoya en unas pocas librerías de Python. Antes de escribir código conviene tener claro qué papel cumple cada una.

1. Crea un notebook nuevo y coloca el archivo **insurance.csv** en la misma carpeta.
2. Importa **pandas** para manejar la tabla de datos y **matplotlib.pyplot** para graficar.
3. Desde scikit-learn importa **train_test_split** (módulo **model_selection**), **LinearRegression** (módulo **linear_model**) y las métricas **r2_score** y **mean_absolute_error** (módulo **metrics**).

PARA ENTREGAR

La celda de importaciones ejecutada sin errores y una tabla breve que indique, con tus palabras, para qué usarás cada librería o función importada.

PASO 02

Cargar y conocer los datos

Antes de entrenar cualquier modelo hay que ver cómo son los datos: cuántos registros hay, qué columnas tienen y qué tipo de valores contienen.

1. Carga el archivo con **pd.read_csv** en un DataFrame llamado **df**.
2. Muestra las dimensiones de la tabla con **df.shape** y las primeras filas con **df.head()**.

3. Revisa el tipo de cada columna con `df.info()`.

PARA ENTREGAR

Las salidas de las tres instrucciones. Responde: ¿cuántos asegurados y cuántas columnas tiene el dataset? ¿Qué representa una fila? ¿Qué columnas contienen texto y cuáles contienen números? ¿Cuál es la variable que queremos predecir?

PASO 03

Preparar los datos para el modelo

La regresión lineal solo trabaja con números, pero `sex`, `smoker` y `region` contienen texto. La técnica *one-hot encoding* convierte cada variable categórica en columnas de 0 y 1. Además, hay que separar las variables de entrada de la variable objetivo.

1. Separa la variable objetivo en `y` (la columna `charges`) y las variables de entrada en `X` (todas las demás columnas).
2. Codifica las variables categóricas de `X` con `pd.get_dummies(..., drop_first=True, dtype=int)`.
3. Imprime la lista de columnas resultante con `list(X.columns)` y muestra las primeras filas de `X`.

PARA ENTREGAR

La lista de columnas de `X`. Responde: ¿en cuántas columnas se convirtieron las 6 variables originales? ¿Qué categoría de cada variable quedó como **referencia** (la que no tiene columna propia)? Explica qué hace `drop_first=True` y por qué no se pierde información al usarlo.

PASO 04

Dividir en entrenamiento y prueba

Un modelo debe evaluarse con datos que no usó para aprender; de lo contrario, su desempeño parecería mejor de lo que realmente es. Por eso los datos se separan en un conjunto de **entrenamiento** y uno de **prueba**.

1. Divide `X` e `y` con `train_test_split`, reservando el 20 % para prueba (`test_size=0.2`) y usando `random_state=42`.
2. Imprime cuántas filas quedaron en cada conjunto.

PARA ENTREGAR

El tamaño de cada conjunto. Responde: ¿por qué no se debe evaluar el modelo con los mismos datos con los que se entrenó? ¿Qué función cumple `random_state` y qué pasaría con tus resultados si no lo fijas?

PASO 05

Entrenar el modelo

Entrenar un modelo de regresión lineal significa encontrar el intercepto y los coeficientes que hacen que las predicciones se parezcan lo más posible a los costos reales del conjunto de entrenamiento.

1. Crea un modelo con `LinearRegression()` y guárdalo en una variable llamada `modelo`.
2. Entrénalo con `modelo.fit(X_train, y_train)`.

PARA ENTREGAR

La celda de entrenamiento ejecutada. Responde: ¿qué calcula exactamente el método `fit`? ¿Qué criterio usa la regresión lineal para decidir cuáles son los "mejores" coeficientes? Escribe la ecuación general del modelo con las variables de tu `X`.

PASO 06

Evaluar el modelo

Para saber si el modelo es útil se comparan sus predicciones con los costos reales del conjunto de prueba. Usarás dos métricas: el R^2 , que indica qué proporción de la variación del costo explica el modelo, y el **MAE** (error absoluto medio), que indica en cuántos dólares se equivoca en promedio.

1. Obtén las predicciones del conjunto de prueba con `modelo.predict(X_test)` y guárdalas en `y_pred`.
2. Calcula el R^2 con `r2_score(y_test, y_pred)` y el MAE con `mean_absolute_error(y_test, y_pred)`.
3. Calcula también la mediana de `charges` para tener una referencia de cuánto cuesta un seguro típico.

PARA ENTREGAR

Los valores de R^2 y MAE. Responde: ¿qué significa cada uno en el contexto del problema? Compara el MAE con la mediana del costo: ¿el error es pequeño o grande para la compañía de seguros? ¿Consideras que el modelo es aceptable? Justifica.

PASO 07

Interpretar los coeficientes

La gran ventaja de la regresión lineal es que se puede interpretar. Cada coeficiente indica cuánto cambia el costo anual, en dólares, cuando su variable aumenta en una unidad y las demás se mantienen fijas. En las variables de 0 y 1, el coeficiente es la diferencia respecto de la categoría de referencia.

1. Muestra el intercepto con `modelo.intercept_`.

2. Crea una serie de Pandas que asocie cada coeficiente (`modelo.coef_`) con el nombre de su columna (`X.columns`) y ordénala de menor a mayor.

PARA ENTREGAR

La tabla de coeficientes. Responde: ¿qué variable aumenta más el costo? Interpreta en dólares el coeficiente de una variable numérica y el de una variable binaria, mencionando la categoría de referencia. ¿Tiene sentido práctico el valor del intercepto? Finalmente, explica por qué un coeficiente pequeño no significa necesariamente que su variable tenga poca influencia (pista: considera el rango de valores que toma cada variable).

PASO 08

Visualizar las predicciones

Las métricas resumen el desempeño en un solo número; un gráfico permite ver **dónde** acierta y dónde falla el modelo. En un gráfico de costo real frente a costo predicho, una predicción perfecta caería exactamente sobre la diagonal.

1. Dibuja un diagrama de dispersión con `plt.scatter`, con el costo real (`y_test`) en el eje horizontal y el costo predicho (`y_pred`) en el vertical.
2. Traza la diagonal de predicción perfecta (predicho = real) como una línea discontinua.
3. Agrega título y etiquetas a los ejes, indicando las unidades.

PARA ENTREGAR

El gráfico y una lectura escrita. Responde: ¿en qué rango de costos predice mejor el modelo y en cuál peor? ¿Los puntos alejados están por encima o por debajo de la diagonal, y qué significa eso (sobrestimar o subestimar)? ¿Observas grupos de puntos separados? Formula una hipótesis sobre qué tipo de asegurados provoca los mayores errores.

PASO 09

Predecir el costo de nuevos solicitantes

Un modelo entrenado se usa para estimar casos nuevos. Para ello, los datos nuevos deben prepararse **exactamente igual** que los de entrenamiento: mismas columnas, en el mismo orden.

1. Crea un DataFrame con los tres solicitantes de la tabla siguiente.
2. Codifica sus variables con `pd.get_dummies` y alinea las columnas con las de `X` usando `reindex(columns=X.columns, fill_value=0)`.
3. Predice el costo anual de cada solicitante con `modelo.predict`.

Solicitante	age	sex	bmi	children	smoker	region
A	45	male	33.5	2	yes	southeast
B	45	male	33.5	2	no	southeast
C	25	female	22.0	0	no	northwest

PARA ENTREGAR

Las tres predicciones. Responde: ¿por qué es necesario el paso de **reindex**? ¿Qué ocurriría sin él? Los solicitantes A y B solo difieren en una característica: ¿cuánto cambia la predicción entre ellos y qué coeficiente del Paso 07 explica esa diferencia?