

INF672 / Unidad 1 / Fundamentos

UNIDAD 1

Fundamentos del Machine Learning

De la programación por reglas al aprendizaje a partir de datos: qué es el ML, dónde vive dentro de la IA y la ciencia de datos, cómo se clasifican los algoritmos y con qué herramientas trabajaremos en Python.

Machine Learning

6º semestre

Plan Curricular 2025

Ing. Informática · UATF

CONTENIDO DE LA UNIDAD

- 1.1 Contexto y motivación del Machine Learning
- 1.2 El Machine Learning dentro de la ciencia de datos y la IA
- 1.3 ¿Qué es el Machine Learning?
- 1.4 Taxonomía del aprendizaje
- 1.5 Entorno de trabajo en Python

1.1 Contexto y motivación del Machine Learning

Durante las últimas dos décadas, tres fuerzas se combinaron para transformar la manera en que construimos software inteligente. La primera es la **explosión de datos**: cada búsqueda, compra, sensor, foto o transacción deja un rastro digital, y hoy generamos volúmenes de información que hace veinte años eran impensables. La segunda es el **aumento de la capacidad de cómputo**, en particular las GPU y la computación en la nube, que permiten procesar esos datos a bajo costo. La tercera es la **madurez de los algoritmos y las librerías de código abierto**, que ponen técnicas antes reservadas a laboratorios de investigación al alcance de cualquier estudiante con una laptop.

Para entender la motivación del Machine Learning conviene contrastarlo con la programación tradicional. En el enfoque clásico, el programador estudia el problema, deduce un conjunto de reglas y las escribe explícitamente en el código. Este enfoque funciona bien mientras las reglas sean claras y estables. El problema aparece cuando las reglas son demasiadas, cambian con el tiempo o simplemente no las conocemos.

EJEMPLO · EL FILTRO DE SPAM

Imagina que debes programar un filtro de correo no deseado con reglas escritas a mano. Empezarías marcando como spam los mensajes que contienen palabras como «gratis», «oferta» o «ganaste». Pronto los remitentes escriben «g r a t i s» o «GR4T1S» para evadir tu regla, y tú agregas otra regla, y otra más. El resultado es un programa enorme, frágil y difícil de mantener: una lista interminable de excepciones que envejece mal.

Un sistema de Machine Learning aborda el mismo problema al revés: en lugar de que tú escribas las reglas, **el algoritmo aprende por sí mismo qué patrones distinguen el spam del correo legítimo** a partir de

miles de ejemplos ya clasificados. Cuando aparecen trucos nuevos, basta con reentrenar el modelo con datos recientes; no hay que reescribir el programa.

Este cambio de paradigma explica por qué el Machine Learning brilla precisamente en los problemas donde la programación clásica fracasa:

- **Problemas sin solución algorítmica sencilla**, como reconocer objetos en imágenes o transcribir voz: nadie sabe escribir a mano las reglas para «esto es un gato».
- **Problemas con demasiadas reglas y excepciones**, como el filtro de spam, donde el enfoque manual se vuelve inmanejable.
- **Entornos cambiantes**, donde un sistema que aprende puede adaptarse a datos nuevos sin intervención humana constante.
- **Descubrimiento de patrones ocultos** en grandes volúmenes de datos, algo que ayuda a los humanos a comprender el fenómeno (esto se conoce como *data mining*).

El Machine Learning ya forma parte invisible de la vida cotidiana: las recomendaciones de películas y productos, los asistentes de voz, la detección de fraude en tarjetas, los filtros de imágenes, la traducción automática y los sistemas de diagnóstico médico funcionan, en su núcleo, gracias a modelos que aprendieron de datos. Comprender sus fundamentos ya no es un lujo académico, sino una competencia central para el ingeniero informático.

1.2 El Machine Learning dentro de la ciencia de datos y la inteligencia artificial

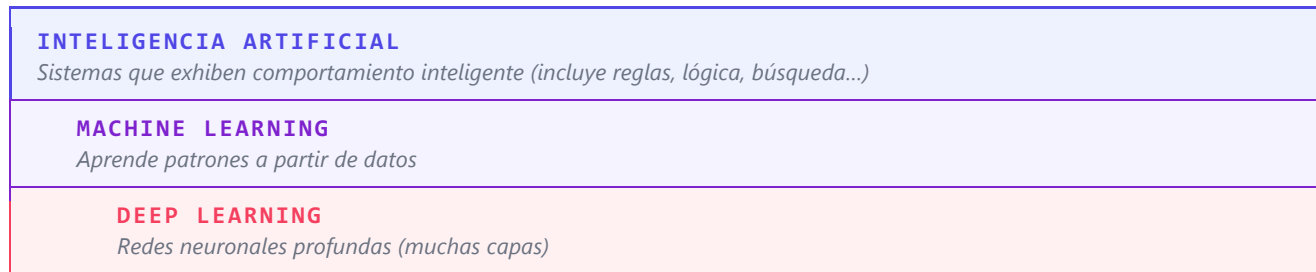
Es común usar como sinónimos «inteligencia artificial», «machine learning», «deep learning» y «ciencia de datos». En rigor son conceptos distintos que se relacionan como círculos que se contienen o se superponen. Ubicarlos correctamente evita confusiones y ayuda a elegir la herramienta adecuada para cada problema.

Inteligencia artificial $\supset$ Machine Learning $\supset$ Deep Learning

La **inteligencia artificial (IA)** es la disciplina más amplia: busca que las máquinas realicen tareas que asociamos con la inteligencia humana (razonar, percibir, planificar, decidir). Incluye enfoques basados en reglas y lógica simbólica que no aprenden de datos.

El **Machine Learning (ML)** es un subcampo de la IA: agrupa las técnicas que permiten a los sistemas *aprender a partir de datos* en lugar de ser programados explícitamente. No toda la IA es ML, pero todo ML es IA.

El **Deep Learning (DL)** es, a su vez, un subcampo del ML: emplea **redes neuronales artificiales con muchas capas** y es responsable de los avances más espectaculares en visión por computadora y procesamiento de lenguaje. Es ML especializado, no una categoría aparte.

Fig. 1.1 — Relación de contención: $DL \subset ML \subset IA$.

¿Y la ciencia de datos?

La **ciencia de datos** no es un subconjunto de la IA, sino un campo interdisciplinario que se *superpone* con el ML. Su objetivo es extraer conocimiento y valor de los datos combinando tres pilares: **matemática y estadística, programación y computación, y conocimiento del dominio**. Abarca todo el ciclo de vida del dato: obtención, limpieza, exploración, visualización, modelado y comunicación de resultados.

IDEA CLAVE

El Machine Learning es el **motor de modelado y predicción** dentro del proceso más amplio de la ciencia de datos. Un científico de datos dedica gran parte de su tiempo a obtener, limpiar y entender los datos (etapas que veremos en la Unidad 2); el ML entra en escena cuando esos datos ya preparados se usan para construir modelos que predicen o descubren estructura.

Concepto	Qué es	Relación
IA	Máquinas que imitan la inteligencia humana	Campo más amplio
ML	Aprender de datos sin reglas explícitas	Subcampo de la IA
DL	Redes neuronales profundas	Subcampo del ML
Ciencia de datos	Ciclo completo del dato: valor a partir de datos	Se superpone con el ML

1.3 ¿Qué es el Machine Learning?

Existen dos definiciones clásicas que, juntas, capturan bien la esencia del campo: una intuitiva y otra formal.

DEFINICIÓN · ARTHUR SAMUEL (1959)

El Machine Learning es el **campo de estudio que da a las computadoras la capacidad de aprender sin ser programadas explícitamente**.

Esta definición es memorable pero informal. Una formulación más precisa y operativa la dio Tom Mitchell en 1997, y es la que usaremos como referencia en el curso.

DEFINICIÓN · TOM MITCHELL (1997)

Se dice que un programa **aprende** de una experiencia **E** con respecto a una tarea **T** y una medida de desempeño **P**, si su desempeño en **T**, medido por **P**, mejora con la experiencia **E**.

La virtud de esta definición es que obliga a nombrar explícitamente los tres ingredientes de todo sistema de ML. Apliquémosla al filtro de spam:

Elemento	En el filtro de spam
T — Tarea	Clasificar correos como «spam» o «no spam»
E — Experiencia	Un conjunto de correos ya etiquetados como spam / no spam
P — Desempeño	La proporción de correos clasificados correctamente (exactitud)

El conjunto de ejemplos que el sistema usa para aprender se llama **conjunto de entrenamiento** (*training set*), y cada ejemplo individual es una **instancia** o muestra. Cada instancia se describe mediante **atributos** o **características** (*features*): por ejemplo, la frecuencia de ciertas palabras en el correo. En el aprendizaje supervisado, además, cada instancia trae una **etiqueta** (*label*), que es la respuesta correcta que el modelo debe aprender a predecir.

VOCABULARIO QUE SE REPETIRÁ TODO EL SEMESTRE

instancia/muestra · característica (feature) · etiqueta (label) · conjunto de entrenamiento
· conjunto de prueba · modelo · predicción

1.4 Taxonomía del aprendizaje

Existen muchísimos algoritmos de Machine Learning, por lo que resulta útil clasificarlos según distintos criterios. Estos criterios no son excluyentes: un mismo algoritmo puede describirse simultáneamente como «supervisado», «por lotes» y «basado en modelos». Veremos los tres ejes de clasificación más importantes.

1.4.1 Aprendizaje supervisado y no supervisado

El primer criterio es la **cantidad y el tipo de supervisión** que recibe el sistema durante el entrenamiento, es decir, si los datos vienen o no con etiquetas.

Aprendizaje supervisado

Los datos de entrenamiento incluyen las **respuestas deseadas (etiquetas)**. El modelo aprende la relación entre las características y la etiqueta para predecir la etiqueta de datos nuevos. Se divide en dos grandes tareas:

- **Clasificación:** la etiqueta es una categoría (spam/no spam, dígito 0–9, tipo de flor). *La salida es discreta.*
- **Regresión:** la etiqueta es un valor numérico continuo (precio de una casa, temperatura, ventas). *La salida es continua.*

Aprendizaje no supervisado

Los datos **no tienen etiquetas**. El sistema intenta descubrir por sí mismo la estructura oculta en los datos. Tareas típicas:

- **Agrupamiento (clustering):** dividir los datos en grupos de instancias similares, sin saber de antemano cuáles son (segmentar clientes, por ejemplo).
- **Reducción de dimensionalidad:** simplificar los datos conservando la información esencial, útil para visualizar o comprimir.
- **Detección de anomalías:** identificar instancias inusuales (fraude, fallas de un sensor).

ENTRE AMBOS EXTREMOS

Existen categorías intermedias: el **aprendizaje semisupervisado** combina muchos datos sin etiquetar con unos pocos etiquetados, y el **aprendizaje por refuerzo**, donde un agente aprende mediante ensayo y error recibiendo recompensas o penalizaciones. En este curso nos centraremos en el supervisado y el no supervisado.

Criterio	Supervisado	No supervisado
¿Datos etiquetados?	Sí	No
Objetivo	Predecir una etiqueta	Descubrir estructura oculta
Tareas	Clasificación, regresión	Clustering, reducción dim.
Ejemplo	Filtro de spam	Segmentar clientes

1.4.2 Aprendizaje online y batch

El segundo criterio es **si el sistema puede aprender de forma incremental a partir de un flujo de datos** o no.

- **Aprendizaje por lotes (batch / offline)**: el sistema se entrena con **todos los datos disponibles de una sola vez**. Como suele requerir mucho tiempo y recursos, se entrena fuera de línea y luego se pone en producción. Si llegan datos nuevos, hay que reentrenar el modelo desde cero con el conjunto completo (viejos + nuevos) y desplegar la nueva versión.
- **Aprendizaje en línea (online)**: el sistema se entrena de forma **incremental**, alimentándolo con instancias de manera secuencial, individualmente o en pequeños grupos (*mini-batches*). Es ideal para sistemas que reciben un flujo continuo de datos (por ejemplo, precios de bolsa) y necesitan adaptarse rápidamente al cambio.

CUIDADO CON EL APRENDIZAJE ONLINE

Un riesgo del aprendizaje en línea es que, si le llegan datos de mala calidad, **el desempeño del modelo puede degradarse gradualmente**. Por eso conviene monitorear el sistema de cerca y poder desactivar el aprendizaje o revertir a un estado anterior si algo sale mal.

1.4.3 Aprendizaje basado en instancias y basado en modelos

El tercer criterio se refiere a **cómo generaliza el sistema**, es decir, cómo hace predicciones sobre datos que nunca vio.

- **Basado en instancias**: el sistema simplemente **memoriza los ejemplos de entrenamiento** y, para clasificar un dato nuevo, lo compara con los ejemplos conocidos usando una medida de similitud. El caso típico es **k-vecinos más cercanos (k-NN)**: para etiquetar una instancia nueva mira las **k** instancias más parecidas y adopta la etiqueta mayoritaria.
- **Basado en modelos**: el sistema construye un **modelo matemático a partir de los ejemplos** (por ejemplo, una recta, una curva o una red neuronal) y luego usa ese modelo para hacer predicciones. Aprender consiste en ajustar los *parámetros* del modelo para que se ajuste lo mejor posible a los datos. La regresión lineal, que veremos en la Unidad 3, es el ejemplo clásico.

LOS TRES EJES, RESUMIDOS

Eje 1 · ¿Con o sin etiquetas? → supervisado / no supervisado

Eje 2 · ¿De golpe o incremental? → batch / online

Eje 3 · ¿Comparar o construir un modelo? → basado en instancias / basado en modelos

1.5 Entorno de trabajo en Python

Python se ha consolidado como el **lenguaje de facto del Machine Learning**. Es sencillo de leer, cuenta con un ecosistema científico maduro y una comunidad enorme. En este curso trabajaremos sobre ese ecosistema, cuya instalación con Anaconda se desarrolla en el laboratorio 1. Aquí conoceremos las herramientas que usaremos día a día.

1.5.1 Jupyter Notebook, JupyterLab y Google Colaboratory

Un **notebook (cuaderno)** es un documento interactivo que combina, en una misma página, **celdas de código ejecutable**, **celdas de texto en Markdown** y las salidas del código (tablas, gráficos, resultados). Esta mezcla de código, explicación y resultado en un solo lugar es ideal para experimentar, documentar y enseñar ML: por eso los materiales de esta materia adoptan justamente ese estilo de «cuaderno científico».

- **Jupyter Notebook**: la interfaz clásica, basada en el navegador. Cada cuaderno es un archivo `.ipynb` y se organiza en celdas que se ejecutan de forma independiente. Simple y muy difundida.
- **JupyterLab**: la evolución de Jupyter Notebook. Ofrece una interfaz tipo IDE con pestañas, explorador de archivos, terminal y varios cuadernos abiertos a la vez. Es el entorno recomendado para trabajo local más serio.
- **Google Colaboratory (Colab)**: un servicio gratuito de Google que ejecuta cuadernos **en la nube, sin instalar nada**. Basta un navegador y una cuenta de Google. Guarda los cuadernos en Google Drive, facilita compartarlos y ofrece acceso gratuito a GPU, lo que lo hace muy útil para deep learning y para trabajar desde cualquier computadora.

LOS TRES EJECUTAN EL MISMO TIPO DE CUADERNO

Jupyter Notebook, JupyterLab y Colab abren y ejecutan archivos `.ipynb`. La diferencia está en **dónde corre el código** (tu máquina vs. la nube) y en la comodidad de la interfaz, no en el lenguaje ni en las librerías. Lo que aprendas en uno se traslada a los otros.

Herramienta	Dónde se ejecuta	Ideal para
Jupyter Notebook	Local (navegador)	Empezar, pruebas rápidas
JupyterLab	Local (IDE web)	Proyectos locales más grandes
Google Colab	Nube (Google)	Sin instalar nada, GPU gratis

1.5.2 NumPy, Pandas y Matplotlib

Sobre Python se apoya una pila de librerías científicas que forman la base de casi todo el trabajo en ML. Estas tres son las fundamentales y las usaremos en cada laboratorio:

- **NumPy** (Numerical Python): introduce el **arreglo n-dimensional (ndarray)**, una estructura para hacer cálculo numérico y operaciones vectoriales de forma rápida y eficiente. Es la base sobre la que se construyen las demás librerías; en ML, los datos casi siempre viven como arreglos y matrices de NumPy.
- **Pandas**: ofrece el **DataFrame**, una tabla etiquetada (filas y columnas) parecida a una hoja de cálculo, para **cargar, limpiar, transformar y explorar datos**. Es la herramienta central del preprocesamiento: leer un CSV, filtrar filas, tratar valores faltantes, agrupar y resumir.

- **Matplotlib:** la librería de **visualización** por excelencia. Permite crear gráficos de líneas, dispersión, histogramas, barras y mucho más para entender los datos y comunicar resultados. Sobre ella se construyen librerías de más alto nivel como Seaborn.

Un vistazo mínimo a las tres trabajando juntas, en el estilo de cuaderno que usaremos todo el semestre:

```
In [1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# NumPy: un arreglo y una operación vectorial
x = np.array([1, 2, 3, 4, 5])
print("media:", x.mean())
```

```
Out[1]: media: 3.0
```

```
In [2]: # Pandas: una tabla etiquetada (DataFrame)
df = pd.DataFrame({
    "largo": [5.1, 4.9, 6.3],
    "ancho": [3.5, 3.0, 3.3],
    "clase": ["setosa", "setosa", "virginica"]
})
df.head()
```

```
Out[2]:      largo  ancho  clase
0     5.1    3.5   setosa
1     4.9    3.0   setosa
2     6.3    3.3  virginica
```

```
In [3]: # Matplotlib: un gráfico de dispersión
plt.scatter(df["largo"], df["ancho"])
plt.xlabel("largo del sépalo")
plt.ylabel("ancho del sépalo")
plt.show()
```

```
Out[3]: [gráfico de dispersión largo vs. ancho]
```

HACIA DÓNDE VAMOS

En la **Unidad 2** profundizaremos en estas tres librerías y en el preprocesamiento de datos usando el conjunto **iris** como caso recurrente. Por ahora, lo esencial es reconocer el ecosistema: **NumPy para calcular, Pandas para manejar tablas y Matplotlib para visualizar**, todo dentro de un cuaderno interactivo.

Síntesis de la unidad

- El ML surge para resolver problemas donde escribir reglas a mano es inviable: aprende **patrones a partir de datos**.

- Jerarquía: **Deep Learning** $\subset$ **Machine Learning** $\subset$ **Inteligencia Artificial**; el ML es el motor de modelado dentro de la ciencia de datos.
- Definición operativa (Mitchell): un programa aprende de una experiencia **E** en una tarea **T** medida por **P**.
- Tres ejes de taxonomía: supervisado/no supervisado, batch/online, basado en instancias/en modelos.
- Entorno de trabajo: cuadernos (Jupyter/JupyterLab/Colab) y la pila NumPy + Pandas + Matplotlib.