

INF672 / Unidad 2 / 2.1.1

REPASO MATEMÁTICO · ÁLGEBRA LINEAL

Vectores, matrices y producto punto

Alineación, longitud y distancia entre vectores

Universidad Autónoma Tomás Frías · Facultad de Ciencias Puras · Ingeniería Informática
Machine Learning (INF672) · Gestión 2026-02 · Docente: M. Sc. Huáscar F. Gonzales G.

En Machine Learning casi todo dato se representa como un **vector**: una fila de características (*features*) de una tabla, la representación numérica de una palabra o un documento (*embedding*), una imagen aplanada en una lista de píxeles, etc. Trabajar con datos es, en el fondo, trabajar con vectores.

Sobre esos vectores nos hacemos tres preguntas fundamentales, y este repaso cubre exactamente esas tres:

- **¿Qué tan alineados están dos vectores?** → producto punto y similitud coseno.
- **¿Qué tan lejos está uno de otro?** → distancia (euclidiana y otras).
- **¿Cuál es su tamaño (longitud)?** → norma.

EN MACHINE LEARNING

Estas operaciones son la base de algoritmos como **k-NN** (clasificación por vecinos cercanos), **k-means** (agrupamiento), los **sistemas de recomendación** y el **procesamiento de lenguaje natural**. Dominar el álgebra vectorial es el primer paso para entender cómo "piensan" estos modelos.

NOTA · NOTACIÓN

Los vectores se escriben en **negrita** (**a**, **b**) o con una flecha encima ($\vec{a}$). Sus componentes llevan subíndices: $\mathbf{a} = (a_1, a_2, \dots, a_n)$. El número de componentes es la **dimensión** del vector.


1. Repaso rápido: ¿qué es un vector?

Un **vector** es una lista ordenada de números. Admite dos lecturas complementarias, y en ML usamos ambas todo el tiempo:

- **Lectura algebraica:** es la tupla de sus componentes, $\mathbf{a} = (2, 4)$. Así lo guarda la computadora (un arreglo de NumPy).
- **Lectura geométrica:** es una *flecha* con **dirección** y **magnitud** (longitud), que parte del origen y llega al punto (2, 4).

EJEMPLO

El vector $\mathbf{a} = (2, 4)$ puede verse como el punto $(2, 4)$ en el plano, o como la flecha que va del origen a ese punto. Un vector de características en ML puede tener muchas dimensiones, por ejemplo $\mathbf{x} = (2, 4, 6, 20, \dots, 40)$, que no podemos dibujar, pero con el que operamos con las mismas fórmulas.

El vector como flecha

Los vectores $\mathbf{a}=(2,4)$ y $\mathbf{b}=(4,3)$ dibujados como flechas que parten del origen. Sirve para ver la "lectura geométrica": dirección + longitud.

2. Producto punto (producto escalar)

El **producto punto** toma dos vectores y devuelve **un solo número** (un escalar; de ahí "producto escalar"). Es la operación más importante del álgebra lineal aplicada.

2.1 Forma algebraica

Se multiplican las componentes **una a una** (la primera con la primera, la segunda con la segunda...) y se suman todos los productos:

$$\mathbf{a} \cdot \mathbf{b} = \sum a_i b_i = a_1 b_1 + a_2 b_2 + \dots + a_n b_n$$

(la suma recorre las componentes $i = 1, 2, \dots, n$).

Ejemplo. Con $\mathbf{a} = (2, 4)$ y $\mathbf{b} = (4, 3)$:

$$\begin{aligned} \mathbf{a} \cdot \mathbf{b} &= (2)(4) + (4)(3) \\ &= 8 + 12 \\ &= 20 \end{aligned}$$

En NumPy, exactamente la misma cuenta:

```
In [1]: import numpy as np; a = np.array([2,4]); b = np.array([4,3]); np.dot(a, b)
Out[1]: 20
```

2.2 Forma geométrica y norma

El mismo número puede escribirse con las longitudes de los vectores y el ángulo α que forman:

$$\mathbf{a} \cdot \mathbf{b} = \|\mathbf{a}\| \cdot \|\mathbf{b}\| \cdot \cos \alpha$$

Aquí $\|\mathbf{a}\|$ es la **norma** (longitud) del vector, que se obtiene con el **teorema de Pitágoras** generalizado:

$$\|\mathbf{a}\| = \sqrt{a_1^2 + a_2^2 + \dots + a_n^2}$$

NOTA · PUENTE ÚTIL

Si multiplicamos un vector por sí mismo obtenemos el cuadrado de su longitud: $\mathbf{a} \cdot \mathbf{a} = \|\mathbf{a}\|^2$. Es el puente entre producto punto y norma.

2.3 Propiedades

El producto punto cumple reglas que lo hacen cómodo de manipular:

- **Conmutativa:** $\mathbf{a} \cdot \mathbf{b} = \mathbf{b} \cdot \mathbf{a}$
- **Distributiva:** $\mathbf{a} \cdot (\mathbf{b} + \mathbf{c}) = \mathbf{a} \cdot \mathbf{b} + \mathbf{a} \cdot \mathbf{c}$
- **Homogénea:** $(k \cdot \mathbf{a}) \cdot \mathbf{b} = k(\mathbf{a} \cdot \mathbf{b})$ (k es un escalar)
- **Relación con la norma:** $\mathbf{a} \cdot \mathbf{a} = \|\mathbf{a}\|^2$

Y sobre todo, el **signo** del resultado ya nos dice algo geométrico:

Si $\mathbf{a} \cdot \mathbf{b}$ es...	Significado geométrico
mayor que 0	Los vectores apuntan, a grandes rasgos, en la misma dirección (ángulo agudo).
igual a 0	Los vectores son perpendiculares (ortogonales).
menor que 0	Los vectores apuntan en direcciones opuestas (ángulo obtuso).

EJEMPLO · ORTOGONALIDAD

Los ejes $\mathbf{a} = (1, 0)$ y $\mathbf{b} = (0, 1)$ son perpendiculares, y en efecto $\mathbf{a} \cdot \mathbf{b} = (1)(0) + (0)(1) = 0$.

3. Similitud coseno

Si en la forma geométrica despejamos el coseno del ángulo, obtenemos la **similitud coseno**: una medida de qué tan alineadas están las **direcciones** de dos vectores, **ignorando por completo sus longitudes**.

DEFINICIÓN

$$\cos \alpha = (\mathbf{a} \cdot \mathbf{b}) / (\|\mathbf{a}\| \cdot \|\mathbf{b}\|)$$

Y si queremos el ángulo en sí, aplicamos el arccoseno:

$$\alpha = \arccos((\mathbf{a} \cdot \mathbf{b}) / (\|\mathbf{a}\| \cdot \|\mathbf{b}\|))$$

3.1 Ejemplo completo: ángulo entre dos vectores

Determinar el ángulo que forman $\mathbf{a} = (2, 3)$ y $\mathbf{b} = (-1, 4)$.

Paso 1 – producto punto:

$$\mathbf{a} \cdot \mathbf{b} = (2)(-1) + (3)(4) = -2 + 12 = 10$$

Paso 2 – normas:

$$\|\mathbf{a}\| = \sqrt{2^2 + 3^2} = \sqrt{13} \approx 3.606$$

$$\|\mathbf{b}\| = \sqrt{(-1)^2 + 4^2} = \sqrt{17} \approx 4.123$$

Paso 3 – similitud:

$$\cos \alpha = 10 / (\sqrt{13} \cdot \sqrt{17}) = 10/\sqrt{221} \approx 0.6727$$


Paso 4 – ángulo:

$$\alpha = \arccos(0.6727) \approx 47.7^\circ$$

Comprobado con NumPy (la similitud coseno como una sola expresión):

```
In [2]: a=np.array([2,3]); b=np.array([-1,4]);
np.dot(a,b)/(np.linalg.norm(a)*np.linalg.norm(b))
Out[2]: 0.6726727939963124
```

Ángulo entre $\mathbf{a}=(2,3)$ y $\mathbf{b}=(-1,4)$



Los dos vectores del ejemplo y el arco del ángulo $\alpha \approx 47.7^\circ$ entre ellos. Da sentido geométrico a la similitud coseno.

3.2 Cómo interpretar el valor

La similitud coseno siempre cae en el rango $[-1, 1]$, y se lee así:

$\cos \alpha \approx$	Interpretación
1	Misma dirección → vectores muy parecidos.
0	Perpendiculares (ortogonales) → sin relación.
-1	Direcciones opuestas → vectores contrarios.

3.3 Producto punto vs. similitud coseno

Ambos usan el producto punto, pero miden cosas distintas. La clave: el producto punto **sí** depende de las longitudes; la similitud coseno las **cancela** al dividir por las normas.

	Producto punto	Similitud coseno
¿Depende de la magnitud?	Sí, las longitudes determinan el resultado	No, solo importa la dirección
Rango	Cualquier número real	Entre -1 y 1
Qué mide	Dirección y tamaño a la vez	Únicamente la alineación de direcciones

EN MACHINE LEARNING

La similitud coseno es la métrica estrella en NLP y sistemas de recomendación. Dos documentos sobre el mismo tema pueden tener longitudes muy distintas (uno corto, otro largo); la similitud coseno los reconoce como parecidos porque mira la dirección del vector de palabras, no su tamaño. Lo mismo aplica al comparar embeddings de palabras u ofrecer productos afines a un usuario.

4. Distancia

La **distancia** responde a "¿qué tan lejos está un punto de otro?". También nace del teorema de Pitágoras.

4.1 Del teorema de Pitágoras a la distancia

En un triángulo rectángulo con catetos a y b , la hipotenusa h cumple:

$$h^2 = a^2 + b^2 \quad \Rightarrow \quad h = \sqrt{a^2 + b^2}$$

Si tomamos dos puntos $A = (a_1, a_2)$ y $B = (b_1, b_2)$, los catetos son las diferencias de sus coordenadas, y la hipotenusa es justo la distancia entre ellos:

DEFINICIÓN

$$d(A,B) = \sqrt{(a_1-b_1)^2 + (a_2-b_2)^2}$$

4.2 Generalización: distancia euclidiana en n dimensiones

La idea se extiende a cualquier número de dimensiones. Esta es la **distancia euclidiana**, la "distancia en línea recta" de toda la vida:


$$d(a,b) = \sqrt{(a_1-b_1)^2 + (a_2-b_2)^2 + \dots + (a_n-b_n)^2}$$

Ejemplo del cuaderno. Distancia entre $A = (1, 2)$ y $B = (4, 6)$:

$$\begin{aligned} d &= \sqrt{(1-4)^2 + (2-6)^2} \\ &= \sqrt{(-3)^2 + (-4)^2} = \sqrt{9 + 16} = \sqrt{25} \\ &= 5 \end{aligned}$$

En NumPy, la norma del vector diferencia:

```
In [3]: a=np.array([1,2]); b=np.array([4,6]); np.linalg.norm(a - b)
Out[3]: 5.0
```

La distancia como hipotenusa (Pitágoras)

Los puntos $A=(1,2)$ y $B=(4,6)$, el segmento que los une (la distancia) y el triángulo rectángulo de catetos $\Delta x=3$ y $\Delta y=4$, que da $d=5$.

4.3 Otras métricas de distancia

La euclidiana no es la única forma de medir cercanía. Según el problema conviene otra:

Distancia	Fórmula	Idea
Euclidiana (L2)	$\sqrt{\sum (a_i - b_i)^2}$	Línea recta "a vuelo de pájaro".
Manhattan (L1)	$\sum a_i - b_i $	Recorrido por cuadras, en zigzag horizontal/vertical.
Chebyshev (L∞)	$\max a_i - b_i $	La mayor diferencia en una sola coordenada.

EN MACHINE LEARNING

La distancia es el corazón de k-NN (un dato se clasifica según sus vecinos más cercanos) y de k-means (los puntos se agrupan alrededor del centro más cercano). También sirve para detección de anomalías: un punto muy lejano del resto es sospechoso.

5. Similitud vs. distancia: ¿cuándo usar cada una?

Similitud coseno y distancia euclidiana pueden dar veredictos distintos sobre "qué tan parecidos" son dos vectores, porque miden cosas diferentes.

Criterio	Distancia euclidiana	Similitud coseno
Sensible a la magnitud	Sí	No
Rango de valores	0 (idénticos) a ∞	-1 a 1
¿Más parecido cuando...?	el valor es más pequeño	el valor se acerca a 1
Cuándo conviene	La escala importa (k-NN, k-means)	Importa el patrón, no el tamaño (texto, embeddings)

ADVERTENCIA

Antes de usar distancias, casi siempre hay que normalizar o estandarizar las features. Si una columna va de 0 a 1 y otra de 0 a 100 000, la segunda dominará por completo el cálculo y la primera será invisible. Poner todas las features en una escala comparable es un paso obligatorio del preprocesamiento.

6. Resumen de fórmulas

Concepto	Fórmula	Qué mide
Producto punto	$a \cdot b = \sum a_i b_i$	Alineación + tamaño (un escalar).
Norma (longitud)	$\ a\ = \sqrt{\sum a_i^2}$	El "largo" del vector.
Similitud coseno	$\cos \alpha = a \cdot b / (\ a\ \ b\)$	Alineación de direcciones (-1 a 1).
Ángulo	$\alpha = \arccos(\cos \alpha)$	El ángulo entre ambos vectores.

Concepto	Fórmula	Qué mide
Distancia euclidiana	$d = \sqrt{\sum (a_i - b_i)^2}$	Qué tan lejos está uno de otro.