

INF672 / Unidad 2 / 2.1.2

REPASO MATEMÁTICO · CÁLCULO

El gradiente

La derivada, llevada a funciones de muchas variables

Universidad Autónoma Tomás Frías · Facultad de Ciencias Puras · Ingeniería Informática
Machine Learning (INF672) · Gestión 2026-02 · Docente: M. Sc. Huáscar F. Gonzales G.

Introducción

Casi todos los modelos de aprendizaje automático aprenden de la misma manera: ajustan sus parámetros para minimizar una **función de pérdida** que mide qué tan equivocadas son sus predicciones. El objeto matemático que dirige esa minimización —el que indica, en cada paso, hacia dónde y cuánto mover cada parámetro— es el **gradiente**. Entender el gradiente es, por tanto, entender el motor del entrenamiento.

Este documento construye esa idea desde un punto de partida que ya se domina: la **derivada** de una función de una sola variable. El gradiente no es un concepto nuevo y ajeno, sino esa misma derivada llevada a funciones de muchas variables. Avanzaremos en cuatro pasos —funciones de varias variables, derivadas parciales, el vector gradiente y su interpretación geométrica— y cerraremos conectando todo con el **descenso de gradiente**, el algoritmo con el que se entrena desde una regresión lineal hasta una red neuronal profunda.

Para no perder la intuición, usaremos una sola función de ejemplo a lo largo de todo el texto:

$$f(x, y) = x^2 + 3y^2$$

La elegimos por dos razones: tiene forma de tazón, como una función de pérdida sencilla, y es *asimétrica* —más empujada en una dirección que en otra—, un detalle que más adelante explicará por qué el entrenamiento a veces zigzaguea.

1. De una variable a varias

La derivada que ya se conoce vive en funciones de la forma $f: \mathbb{R} \rightarrow \mathbb{R}$: entra un número y sale un número. El primer paso es aceptar funciones que reciben varios números y devuelven uno solo:

$$f: \mathbb{R}^n \rightarrow \mathbb{R}$$

Se llaman **funciones escalares de varias variables**: varias entradas, una única salida (un escalar). En nuestro ejemplo, $f: \mathbb{R}^2 \rightarrow \mathbb{R}$; la entrada es el par (x, y) y la salida es un número. Por ejemplo, $f(1, 1) = 1 + 3 = 4$ y $f(2, 0) = 4$.

Aquí aparece la conexión con el aprendizaje automático. La función de pérdida $L(\theta)$ de un modelo es exactamente una función escalar de varias variables: recibe el vector de parámetros θ —que puede tener miles o millones de componentes— y devuelve un solo número, el error del modelo. No podremos dibujarla, pero razonaremos sobre ella con las mismas ideas que sobre nuestro tazón de dos variables.

La gráfica. Con una variable, la gráfica de $f(x)$ es una *curva* en el plano. Con dos variables necesitamos tres dimensiones: dos para la entrada (el plano horizontal) y una para la altura $z = f(x, y)$. La gráfica deja de ser una curva y se convierte en una *superficie*. Para $f(x, y) = x^2 + 3y^2$ esa superficie es un tazón (un paraboloide) cuyo fondo está en el origen.




Figura 1. Gráfica de $f(x, y) = x^2 + 3y^2$: un paraboloide con forma de tazón cuyo fondo, en el origen, es el mínimo global.

Curvas de nivel. Como no siempre podemos dibujar la superficie —y para funciones de más de dos variables es imposible—, usamos un recurso de cartógrafo: cortarla a distintas alturas. Fijamos un valor constante $f(x, y) = k$ y observamos qué puntos del plano producen esa altura. En nuestro ejemplo:

$$x^2 + 3y^2 = k$$

Para cada $k > 0$ esto es una *elipse*. Al variar k obtenemos elipses concéntricas, igual que las líneas de un mapa topográfico unen puntos de igual altitud. Donde las curvas están juntas, el terreno es empinado;

donde están separadas, es plano. Conviene retener esta imagen: el gradiente se define en relación con ella.




Figura 2. Curvas de nivel $x^2 + 3y^2 = k$. Son elipses concéntricas; su forma achatada (anchas en x , estrechas en y) revela que la superficie sube más rápido en y que en x .

2. Derivadas parciales

Cuando la función tiene varias entradas surge la pregunta: ¿respecto a cuál derivamos? La respuesta es la **derivada parcial**: se deriva respecto a una variable tratando las demás como constantes. Es la misma definición de límite de siempre, pero congelando el resto:

$$\frac{\partial f}{\partial x}(a, b) = \lim_{h \rightarrow 0} [f(a+h, b) - f(a, b)] / h$$

La segunda variable permanece fija en b mientras solo x se mueve. El símbolo ∂ («de parcial») reemplaza a la d recta para avisar que hay más variables congeladas. En nuestro ejemplo, derivando respecto a x (con y constante, así que $3y^2$ es constante y su derivada es 0):

$$\frac{\partial f}{\partial x} = 2x$$

y derivando respecto a y (con x constante, así que x^2 desaparece):

$$\partial f / \partial y = 6y$$

Cada parcial es una *pendiente*, igual que antes, pero sobre una rebanada de la superficie: si cortamos el tazón con un plano vertical que deja y fijo, obtenemos una curva, y $\partial f / \partial x$ es su pendiente. Evaluadas en el punto $(1, 1)$ valen $\partial f / \partial x = 2$ y $\partial f / \partial y = 6$. Nótese que la pendiente en y triplica a la de x : la superficie es mucho más empinada en la dirección y . Ese desbalance proviene del factor 3 y será importante al final.

3. El vector gradiente

Tenemos dos parciales sueltas. El gradiente simplemente las agrupa en un vector, en orden:

$$\nabla f = (\partial f / \partial x , \partial f / \partial y)$$

El símbolo ∇ es el **operador nabla**. Para una función de n variables el gradiente tiene n componentes. En nuestro ejemplo:

$$\nabla f(x, y) = (2x, 6y) \rightarrow \nabla f(1, 1) = (2, 6)$$

Conviene fijar tres ideas. **Primero**, el gradiente es un vector, no un número: mientras la derivada de una variable daba una sola pendiente, el gradiente reúne de golpe cómo cambia la función en la dirección de cada eje. **Segundo**, es un *campo vectorial*: su valor depende del punto —en $(1, 1)$ vale $(2, 6)$; en el origen vale $(0, 0)$ —, de modo que a cada punto del plano le corresponde su propia flecha. **Tercero**, en aprendizaje automático el gradiente vive en el mismo espacio que los parámetros: si θ tiene un millón de componentes, $\nabla L(\theta)$ también, una derivada parcial por cada peso. Por eso la regla de entrenamiento podrá restarlos componente a componente.

4. Qué significa el gradiente: interpretación geométrica

Esta es la parte que da sentido a todo lo anterior. El gradiente tiene tres propiedades geométricas, y de ellas se deduce el algoritmo de entrenamiento. La figura muestra el campo de gradientes de nuestro tazón, visto desde arriba, sobre sus curvas de nivel.




Figura 3. Campo de gradientes ∇f sobre las curvas de nivel (vista superior). Las flechas apuntan en la dirección de máximo ascenso (A), cruzan las elipses en ángulo recto (C) y son más largas donde la pendiente es mayor, anulándose en el centro (B).

Propiedad A — apunta en la dirección de máximo ascenso. De todas las direcciones en las que podríamos movernos desde un punto, el gradiente señala aquella en la que la función crece más rápido. En la figura, todas las flechas se alejan del centro: «cuesta arriba» es, en todo punto, alejarse del mínimo que está en el fondo del tazón.

Propiedad B — su magnitud mide la pendiente. La longitud del vector, $\|\nabla f\|$, es la tasa de cambio en esa dirección de máximo ascenso: flecha larga, ladera pronunciada; flecha corta, terreno casi plano. En $(1, 1)$ la magnitud es $\|\nabla f(1,1)\| = \sqrt{2^2 + 6^2} = \sqrt{40} \approx 6.32$. En el centro el gradiente se anula, $\nabla f(0, 0) = (0, 0)$: en el fondo del tazón no hay hacia dónde subir.

Propiedad C — es perpendicular a las curvas de nivel. En la figura, cada flecha corta su elipse en ángulo recto. La razón es directa: a lo largo de una curva de nivel la función no cambia (vale siempre k), de modo que la dirección de máximo cambio no puede tener componente alguna a lo largo de la curva y debe salir perpendicular a ella.

5. Del gradiente al descenso de gradiente

Ya podemos explicar cómo aprende un modelo. Estamos en algún punto de la superficie de pérdida y queremos llegar al fondo. El gradiente nos dice hacia dónde *sube* la pérdida más rápido; para bajar, nos movemos en la dirección exactamente *opuesta*, $-\nabla f$. Esa es la regla del **descenso de gradiente**:

$$\theta \leftarrow \theta - \alpha \cdot \nabla L(\theta)$$

donde α es la **tasa de aprendizaje**, que gradúa el tamaño del paso. El signo menos es toda la idea: restar el gradiente es descender por la ruta más empinada. La figura muestra el campo $-\nabla f$: las mismas flechas de antes, pero invertidas, apuntando ahora hacia el mínimo.




Figura 4. Campo $-\nabla f$ (vista superior): las mismas flechas invertidas, apuntando hacia el mínimo. Es la dirección que sigue el descenso de gradiente; entrenar es avanzar por estas flechas hasta el fondo del tazón.

Cada paso del entrenamiento cruza hacia una curva de nivel de menor altura, acercándose al centro. Y como el gradiente se acorta cerca del mínimo (Propiedad B), los pasos se vuelven naturalmente más pequeños a medida que el modelo se aproxima a la solución: el algoritmo «frena solo».

EL ZIGZAG – CUANDO EL DESCENSO NO BAJA RECTO

Como la superficie es más empinada en y que en x (el factor 3), el gradiente es más largo en y , y $-\nabla f$ no apunta exactamente hacia el centro sino inclinado hacia el eje empinado. En consecuencia, un paso de descenso se pasa de largo en y y se queda corto en x ; en la siguiente iteración corrige y vuelve a pasarse, y la trayectoria zigzaguea en lugar de bajar recta. Este fenómeno —causado por la distinta curvatura en cada dirección— es la razón de ser de optimizadores más sofisticados, como Momentum o Adam, que corrigen ese desbalance para que el descenso apunte más directo al mínimo.

6. Hacia dónde continuar

Con estos cuatro conceptos —funciones de varias variables, derivadas parciales, el vector gradiente y su geometría— se tiene el cimiento del gradiente y de su uso en el entrenamiento. Tres temas lo profundizan de forma natural. La **derivada direccional**, $\nabla f \cdot u$, mide la tasa de cambio en cualquier dirección y demuestra con rigor las Propiedades A y C. La **regla de la cadena multivariable** es el motor de la retropropagación (backpropagation), el método con que las redes neuronales calculan ∇L respecto a todos sus pesos. Y la **matriz Hessiana**, formada por las segundas derivadas, describe la curvatura de la superficie de pérdida y explica formalmente el zigzag y el diseño de optimizadores de segundo orden.