

INF672 / Unidad 2 / 2.1.3

REPASO MATEMÁTICO ORIENTADO AL MACHINE LEARNING

Estadística descriptiva

Describir los datos antes de modelarlos

1 Por qué describir antes de modelar

La estadística descriptiva es el arte de resumir en pocos números un conjunto de datos: dónde está su centro, cuánto se dispersan y cómo se relacionan sus variables. En Machine Learning es el paso cero de todo proyecto: antes de entrenar un solo modelo, uno mira los datos. Ese "mirar" no es opcional —decide cómo se limpian los datos, qué características valen la pena y qué modelo tiene sentido.

NOTA · Esto es un repaso, no la asignatura

La teoría completa de la estadística la ven en su materia de Probabilidad y Estadística y Estadística Aplicada a la Ciencia de Datos. Aquí solo reactivamos lo que el ML usa de verdad, y lo calculamos con NumPy y Pandas sobre datos reales. El criterio para incluir un tema no es "¿es importante en estadística?", sino "¿se rompe algo más adelante en el curso si no lo tengo activo?".

Usaremos un único dataset como hilo conductor: iris, con 150 flores descritas por cuatro medidas en centímetros (largo y ancho de sépalo y de pétalo). Cada característica es una variable de la que vamos a describir centro, dispersión, forma y relaciones.

```
In [ ]: import numpy as np, pandas as pd
        from sklearn.datasets import load_iris
        iris = load_iris()
        df = pd.DataFrame(iris.data,
                          columns=['sep_largo', 'sep_ancho', 'pet_largo', 'pet_ancho'])
        df.shape
```

```
Out[ ]: (150, 4)
```

2 Tendencia central: media, mediana y moda

DEFINICIÓN · ¿Dónde está el centro de los datos?

Media — el promedio aritmético: suma de los valores dividida entre cuántos son.

Mediana — el valor central cuando los datos se ordenan; deja la mitad por debajo y la mitad por encima.

Moda — el valor (o categoría) que más se repite.

$$\bar{x} = (1/n) \cdot \sum_i x_i$$

la media de n valores $x_1, x_2, \dots, x_n$

En código

```
In [ ]: col = df['pet_largo']
        col.mean(), col.median()
```

```
Out[ ]: (3.758, 4.35)
```

La media (3.76) y la mediana (4.35) no coinciden, y esa diferencia ya cuenta una historia: los datos no son simétricos. El largo del pétalo tiene un grupo de flores muy pequeñas (la especie setosa) que jala la media hacia abajo mientras la mediana se mantiene en el grueso de los datos.

La idea que importa: la mediana es robusta

Este es el punto que quiero que quede clavado. La media es sensible a valores extremos (outliers); un solo dato absurdo la arrastra. La mediana, en cambio, casi no se mueve, porque solo le importa la posición central, no la magnitud de los extremos.

Un solo outlier arrastra la media, no la mediana




Figura 1. Al inyectar un ancho de sépalo imposible (12 cm), la media salta pero la mediana apenas cambia.

CONEXIÓN ML · Para qué sirve en Machine Learning

Cuando en el preprocesamiento tengas que rellenar valores faltantes (tema 2.3.1), elegirás media o mediana según haya o no outliers: la mediana es la opción segura. La misma robustez es la base de varias técnicas de detección de anomalías.

3 Dispersión: varianza y desviación estándar

El centro no basta: dos características pueden tener la misma media y verse completamente distintas si una está muy concentrada y la otra muy esparcida. La dispersión mide cuánto se alejan los datos de su media.

DEFINICIÓN · Varianza y desviación estándar

Varianza (σ^2) — el promedio de las distancias al cuadrado respecto a la media. Al elevar al cuadrado, castiga más los alejamientos grandes y evita que positivos y negativos se cancelen.

Desviación estándar (σ) — la raíz cuadrada de la varianza. Vuelve a las unidades originales (cm), así que es la que se interpreta.

$$\sigma^2 = (1/n) \cdot \sum_i (x_i - \bar{x})^2 \quad \sigma = \sqrt{\sigma^2}$$

```
In [ ]: col.var(ddof=0), col.std(ddof=0)
```

```
Out[ ]: (3.096, 1.759)
```

NOTA · El detalle del ddof (n vs. n-1)

`np.var` y `np.std` dividen entre `n` por defecto (varianza poblacional). Pandas divide entre `n-1` (varianza muestral, `ddof=1`). La diferencia es mínima con 150 datos y no cambia nada de lo que haremos aquí; solo conviene saber que existe.

Un vistazo a las cuatro características muestra por qué la dispersión importa en la práctica: el largo del pétalo se esparce mucho más ($\sigma \approx 1.76$) que el ancho del sépalo ($\sigma \approx 0.44$).

Característica	media	mediana	desv. σ	rango (min-max)
sep_largo	5.84	5.80	0.83	4.3 – 7.9
sep_ancho	3.06	3.00	0.44	2.0 – 4.4
pet_largo	3.76	4.35	1.76	1.0 – 6.9
pet_ancho	1.20	1.30	0.76	0.1 – 2.5

(El rango —máximo menos mínimo— y los cuartiles dan otras miradas a la dispersión; los cuartiles, el rango intercuartílico y el boxplot pertenecen más a su materia de estadística, así que aquí solo los mencionamos.)

CONEXIÓN ML · Para qué sirve en Machine Learning

Cuando las características viven en escalas muy distintas, los modelos basados en distancia (KNN, K-means) y en gradiente se dejan dominar por la de mayor dispersión. Medir esa dispersión es el primer paso hacia el escalado de características (tema 2.3.3), que resolverá el problema más adelante.

4 La forma de la distribución: leer un histograma

Media y desviación resumen los datos en dos números, pero pierden la forma. El histograma la recupera: agrupa los valores en intervalos y dibuja cuántos datos caen en cada uno. De un vistazo revela cuatro cosas: dónde está el centro, qué tan ancha es la dispersión, si es simétrico o sesgado, y cuántos "picos" tiene (modas).

```
In [ ]: import matplotlib.pyplot as plt
plt.hist(df['pet_largo'], bins=20)
plt.xlabel('Largo del pétalo (cm)'); plt.show()
```




Figura 2. Histograma del largo del pétalo. Se ven dos grupos separados: la media (coral) cae en el hueco entre ambos.

Este histograma es didáctico: tiene dos grupos (es bimodal). El grupo de la izquierda son las flores setosa, claramente separadas del resto. Ese hueco explica por qué la media caía en un punto donde casi no hay datos: cuando la distribución no es unimodal ni simétrica, la media sola engaña.

CONEXIÓN ML · Para qué sirve en Machine Learning

Ver la forma te dice cosas accionables: una característica bimodal probablemente separa bien las clases (aquí, setosa del resto), un sesgo fuerte sugiere transformar la variable, y una cola larga delata outliers. Es intuición previa a cualquier modelo, y la puerta de entrada a la distribución Normal, que veremos en la parte de probabilidad.

5 Relación entre dos variables: correlación

Todo lo anterior describe una variable a la vez. Pero en ML casi siempre interesa cómo se relacionan dos características entre sí. La covarianza mide si dos variables tienden a crecer juntas (positiva), a moverse en sentidos opuestos (negativa) o de forma independiente (cero). Su problema es que su magnitud depende de las unidades, así que es difícil de interpretar.

DEFINICIÓN · Correlación de Pearson

Es la covarianza normalizada para que siempre caiga entre -1 y $+1$, sin importar las unidades. $+1$ = relación lineal positiva perfecta; -1 = negativa perfecta; 0 = sin relación lineal. Es la medida de relación que de verdad se usa.

```
In [ ]: df.corr()          # matriz de correlación 4x4
```




Figura 3. Matriz de correlación de iris. El largo y el ancho del pétalo están casi perfectamente correlacionados (0.96).




Figura 4. El mismo par visto como nube de puntos: al crecer el largo del pétalo crece su ancho, casi en línea recta.

El puente con el álgebra lineal (tema 2.1.1)

Aquí cerramos un círculo que dejamos abierto. La correlación de Pearson entre dos variables es exactamente el coseno del ángulo entre sus vectores centrados (a cada variable se le resta su media). Es la misma similitud coseno del producto punto que vimos en álgebra lineal, aplicada a datos centrados.

$$\text{corr}(x, y) = \cos(x - \bar{x}, y - \bar{y}) = (x - \bar{x}) \cdot (y - \bar{y}) / (\|x - \bar{x}\| \cdot \|y - \bar{y}\|)$$

```
In [ ]: x = df['pet_largo'].values; y = df['pet_ancho'].values
        xc, yc = x - x.mean(), y - y.mean()
        cos = xc @ yc / (np.linalg.norm(xc)*np.linalg.norm(yc))
        np.corrcoef(x, y)[0,1], cos
```

```
Out[ ]: (0.962865, 0.962865) # idénticos
```

CONEXIÓN ML · Para qué sirve en Machine Learning

Dos características muy correlacionadas (como estos dos pétalos, 0.96) cargan casi la misma información: una es casi redundante. Detectarlo guía la selección de características (tema 2.4) —a veces se puede descartar una sin perder poder predictivo— y previene problemas en modelos lineales.

6 Síntesis y fronteras

Todo el repaso descriptivo cabe en una tabla: cada concepto, cómo se calcula en Python y para qué lo vas a usar en el curso.

Concepto	En NumPy / Pandas	Para qué en ML
Media / mediana	<code>.mean()</code> / <code>.median()</code>	Imputar faltantes (2.3.1); la mediana es robusta
Varianza / desv.	<code>.var()</code> / <code>.std()</code>	Ver escalas → escalado (2.3.3)
Histograma	<code>plt.hist(...)</code>	Intuición de forma; separar clases
Correlación	<code>df.corr()</code>	Redundancia → selección (2.4); puente al coseno

FRONTERA · Lo que a propósito queda fuera de este tema

Cuartiles, rango intercuartílico y boxplot a fondo, y la fórmula de la covarianza: pertenecen a su materia de estadística.

El z-score como técnica de escalado es preprocesamiento (tema 2.3.3), no lo adelantamos aquí.

La visualización a fondo con Matplotlib (estilos, subplots, tipos de gráfico) es el tema 2.2.3.

La estadística inferencial (tests de hipótesis, p-valores, intervalos de confianza) no entra en este repaso.