

INF672 / UNIDAD 2 / 2.1.3

Fundamentos de Probabilidad

NOTA ¿Por qué probabilidad en Machine Learning?

Este material cubre solo lo **mínimo indispensable** de probabilidad para poder trabajar con algoritmos de aprendizaje automático. Cada concepto se aplicará en profundidad *cuando llegue el algoritmo que lo usa* (Naive Bayes, regresión logística, árboles de decisión, etc.). Aquí solo construimos el vocabulario común.

Un modelo de ML casi nunca afirma «esto es un gato»; más bien estima «hay un 92 % de probabilidad de que sea un gato». Aprender a partir de datos es, en el fondo, **razonar bajo incertidumbre**. Por eso necesitamos un lenguaje formal para hablar de qué tan probable es algo, cómo cambia esa probabilidad cuando aparece nueva información, y cómo resumir el comportamiento de una cantidad que varía.

1 Nociones básicas

Antes de calcular probabilidades necesitamos tres ideas: el **experimento**, el **espacio muestral** y el **evento**.

DEFINICIÓN

Experimento: un proceso cuyo resultado no se conoce de antemano (lanzar un dado).

Espacio muestral (Ω): el conjunto de todos los resultados posibles. Para un dado, $\Omega = \{1, 2, 3, 4, 5, 6\}$.

Evento: un subconjunto del espacio muestral que nos interesa, p. ej. «salió par» = $\{2, 4, 6\}$.

¿Cómo se asigna una probabilidad?

Hay dos enfoques que conviven en ML:

- **Enfoque clásico:** si todos los resultados son igualmente posibles, $P(\text{evento}) = \text{casos favorables} / \text{casos totales}$. $P(\text{par}) = 3/6 = 0.5$.
- **Enfoque frecuentista:** la probabilidad es la frecuencia relativa a la que ocurre un evento cuando repetimos el experimento muchas veces. Es el enfoque que conecta directamente con los datos: aprendemos probabilidades *contando* sobre el dataset.

Propiedades elementales

$$0 \leq P(A) \leq 1$$

toda probabilidad vive entre 0 (imposible) y 1 (seguro)

$$P(A') = 1 - P(A)$$

regla del complemento: la probabilidad de que A NO ocurra

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

regla de la suma (unión de eventos)

EJEMPLO

En un dataset de 200 correos, 60 son spam. La probabilidad frecuentista de que un correo tomado al azar sea spam es $P(\text{spam}) = 60/200 = 0.30$. Ese simple conteo es la base de clasificadores como Naive Bayes.

2 Probabilidad condicional e independencia

Este es el punto que **más rinde** en todo Machine Learning: casi todo modelo de clasificación estima una probabilidad *condicional* —la probabilidad de una clase *dado* lo que observamos.

DEFINICIÓN

Probabilidad condicional $P(A | B)$: la probabilidad de que ocurra A *sabiendo que* B ya ocurrió. Se lee «probabilidad de A dado B».

$$P(A | B) = P(A \cap B) / P(B)$$

con $P(B) > 0$

Despejando obtenemos la **regla del producto**, útil para calcular la probabilidad de que dos cosas ocurran juntas:

$$P(A \cap B) = P(A | B) \cdot P(B)$$

Independencia

Dos eventos son **independientes** si saber que uno ocurrió no cambia la probabilidad del otro. Muchos modelos *asumen* independencia para simplificar los cálculos (a veces de forma poco realista, como en «Naive Bayes», donde «naive» = ingenuo justo por esa suposición).

$$P(A \cap B) = P(A) \cdot P(B)$$

definición de independencia entre A y B

Teorema de Bayes (como concepto)

El Teorema de Bayes nos dice cómo **actualizar una creencia cuando llega nueva evidencia**. Aquí solo lo presentamos como idea; su uso como clasificador se verá con el algoritmo.

$$P(A \mid B) = P(B \mid A) \cdot P(A) / P(B)$$

La forma de leerlo: partimos de una creencia inicial sobre A (llamada **prior**), observamos evidencia B, y obtenemos una creencia actualizada (llamada **posterior**). Ese ciclo prior → evidencia → posterior reaparecerá una y otra vez.

ATENCIÓN

Cuidado con confundir $P(A \mid B)$ y $P(B \mid A)$: **no son lo mismo**. $P(\text{enfermo} \mid \text{test+}) \neq P(\text{test+} \mid \text{enfermo})$. Intercambiarlas es un error clásico que Bayes ayuda precisamente a evitar.

3 Variables aleatorias

Una **variable aleatoria** es simplemente una función que asigna un número a cada resultado de un experimento. Nos permite pasar de «salió cara» a trabajar con números, que es lo que un algoritmo necesita.

Tipo	Toma valores...	Ejemplo en ML
Discreta	en un conjunto contable (0, 1, 2, ...)	clase predicha, nº de clics, conteo de palabras
Continua	en un rango real (cualquier decimal)	estatura, precio, probabilidad de salida

Cada variable aleatoria tiene asociada una **distribución**, que describe qué tan probable es cada valor:

- En una variable **discreta** usamos una *función de masa de probabilidad* (PMF): asigna una probabilidad a cada valor. La suma de todas es 1.
- En una variable **continua** usamos una *función de densidad* (PDF): aquí la probabilidad de un valor exacto es 0; lo que tiene sentido es la probabilidad de caer en un *intervalo* (el área bajo la curva).

NOTA

Idea clave para retener: una variable aleatoria *no* es un número fijo, sino un número que «puede salir» con cierta distribución. Cuando entrenamos un modelo, tratamos features y etiquetas como variables aleatorias.

4 Distribuciones comunes

Solo necesitamos **reconocer** estas cuatro y saber para qué tipo de dato sirve cada una. Las estudiaremos con detalle cuando aparezcan en un algoritmo.

Distribución	Modela...	Aparece en...
Uniforme	todos los valores igual de probables	inicialización aleatoria, barajado de datos
Bernoulli	un ensayo con dos resultados (éxito/fallo)	clasificación binaria, salida sigmoide
Binomial	nº de éxitos en n ensayos Bernoulli	conteos, pruebas repetidas
Normal	valores agrupados en torno a una media	casi todo: features, errores, pesos

Bernoulli y Binomial

$$\text{Bernoulli: } P(X = 1) = p \quad P(X = 0) = 1 - p$$

un solo ensayo: éxito con probabilidad p

$$\text{Binomial: } P(X = k) = C(n, k) \cdot p^k \cdot (1 - p)^{n-k}$$

probabilidad de k éxitos en n ensayos independientes

Normal (o gaussiana)

Es la más importante por lo omnipresente. Su forma de «campana» queda definida por dos números: la media μ (dónde se centra) y la desviación estándar σ (qué tan ancha es).

$$f(x) = 1 / (\sigma \cdot \sqrt{2\pi}) \cdot e^{-(x - \mu)^2 / (2\sigma^2)}$$

función de densidad de la Normal $N(\mu, \sigma^2)$

NOTA

Aparece tanto por el **Teorema del Límite Central**: la suma/promedio de muchas variables aleatorias tiende a distribuirse de forma normal, sin importar de qué distribución vengan. Por eso la campana surge «sola» en tantos fenómenos.

5 Medidas de resumen

Estas tres sí conviene manejarlas con soltura desde el inicio, porque aparecen **constantemente** y conectan directo con la estadística descriptiva ya vista (media, varianza, desviación).

Esperanza (valor esperado)

Es el «centro de gravedad» de una variable aleatoria: el promedio a largo plazo si repitiéramos el experimento infinitas veces.

$$E[X] = \sum x_i \cdot P(x_i)$$

para una variable discreta: cada valor por su probabilidad

Varianza y desviación estándar

La **varianza** mide qué tan *dispersos* están los valores respecto a la media. La **desviación estándar** es su raíz cuadrada, y tiene la ventaja de estar en las mismas unidades que los datos.

$$\text{Var}(X) = E[(X - \mu)^2] = E[X^2] - \mu^2$$

promedio de las distancias al cuadrado respecto a la media

$$\sigma = \sqrt{\text{Var}(X)}$$

desviación estándar

EJEMPLO

Un dado justo: $E[X] = (1+2+3+4+5+6)/6 = 3.5$. La varianza mide cuánto se alejan típicamente los resultados de ese 3.5.

En ML, un feature con varianza *alta* aporta más información para distinguir ejemplos; uno con varianza casi nula suele ser inútil. Por eso la varianza guía la selección y el escalado de features.

6 Puente hacia los algoritmos

Con estos cinco bloques ya «hablas el idioma» de la probabilidad. A medida que avancemos, cada pieza reaparecerá aplicada:

Concepto de aquí	Se aplicará en...
Prob. condicional + Bayes	Clasificador Naive Bayes
Distribución Normal	Gaussian Naive Bayes, escalado de datos
Bernoulli / softmax	Regresión logística, salida de clasificación
Esperanza	Funciones de pérdida (minimizar error esperado)
Varianza / covarianza	PCA, trade-off sesgo-varianza

NOTA

Estrategia del curso — **matemática just-in-time**: no memorices todo ahora. Domina el vocabulario de este documento y retoma cada fórmula cuando el algoritmo la necesite. Ese es el momento en que «hace clic».